

A parte difícil
não foi o modelo.
Foi escrever
o que a loja sabe.

Construí um agente que lê a caixa de apoio ao cliente de uma loja online e escreve rascunhos. Ligar o modelo à caixa demorou dias.

Escrever as regras do negócio demorou semanas.

O modelo só pode citar 1 088 linhas. Mais nada.

1088

linhas de base
de conhecimento

7

ficheiros, um
por assunto

49

regras confirmadas
pelo lojista

Não inventa políticas, não procura na internet, não deduz por analogia. O que não estiver escrito ali não existe para ele, e o caso escala para uma pessoa.

Escrever aquilo foi a parte do projeto que mais tempo me consumiu, e a que menos se parece com programação.

Uma pergunta simples não é uma regra simples.

A base tem a resposta. Só que ela depende de uma coisa que o cliente quase nunca escreve no email.

PERGUNTA DO CLIENTE

“Quem paga o envio da devolução?”

A loja não emite etiqueta pré-paga

arrependimento
o cliente paga

defeito confirmado
a loja assume

E no segundo caso não é preciso devolver o artigo antigo primeiro, o que muda a resposta inteira.

As duas contradizem-se lidas fora de contexto.

Tiveram de ficar explicitamente ligadas uma à outra, cada uma a apontar para a outra, para o modelo não aplicar a errada com confiança.

Uma base ambígua não produz respostas erradas. *Produz escalões a mais*, porque o agente é instruído a escalar na dúvida.

O custo da ambiguidade aparece na fatura e na carga de trabalho de quem responde. Não aparece na qualidade, que é onde toda a gente o vai procurar.

Cada edição do lojista é um requisito por escrever.

Quando ele muda um rascunho antes de o enviar, está a corrigir uma regra que eu não escrevi.

01 Compara o gerado com o que foi mesmo enviado

02 Agrupa pelo padrão, não pelo email

03 Às 19h o sistema manda-lhe três, no Discord

04 Ele responde. Uma pessoa escreve a regra

Pergunta o *porquê*, nunca propõe a resposta. Uma concordância educada dá uma regra pior do que nenhuma regra.

Na ronda de 3 de setembro: uma pergunta não gerou regra, outra alargou um gatilho, e a terceira revelou um defeito meu.

O guardrail é um @property, não uma instrução.

Descobrir a encomenda de quem escreve produz quatro níveis de confiança. Só os dois primeiros libertam os dados para o prompt.

exata

alta

media

nenhuma

O nível intermédio foi excluído de propósito: é onde há indícios mas não há prova, e é exatamente aí que um engano mostra a encomenda de outra pessoa.

Não é uma regra de prompt que o modelo possa desobedecer.

Ele nunca chega a ver os dados.

A soma de prazos e a validação da decisão saíram do modelo pela mesma razão: em produção, ele mostrou que as fazia mal.

Um guardrail de prompt contorna-se. Um de infraestrutura não.

Sem Mail.Send

A aplicação nunca pediu a permissão de envio ao Microsoft Graph. Não é uma regra no código que alguém possa contornar. É uma permissão que não existe.

Só leitura na loja

O agente lê encomendas e não escreve nenhuma. Nada do que ele decida pode mover dinheiro ou alterar um envio.

Mesmo que todos os outros falhem em simultâneo, o pior resultado possível é *um rascunho errado que uma pessoa lê e apaga.*

Nenhum email sai. Nenhuma encomenda muda.

66% escalavam. Quase todos com razão.

Passei um dia a ler os motivos, um a um, à espera de encontrar automação por fazer.

Ação sobre encomenda	103	exige escrita na plataforma
Compromisso anterior	95	estado que ninguém regista
Julgamento humano	52	garantia, litígio, exceção
Outras seis categorias	47	contexto, identidade, lacuna

Só as lacunas da base é que eram minhas para resolver, e duas fecharam-se nessa semana. As restantes escalam por desenho.

Baixar aquela percentagem exigia dar ao agente escrita na loja, *que é exatamente o guardrail que torna isto tolerável.*

Comparo o que gerei com o que foi mesmo enviado.

182

casos
comparáveis

137

saíram idênticos
ao gerado

16

reescritos
de raiz

A mediana é 100% e a média é 90%. Nenhuma das duas descreve isto: três quartos saem intactos e um em cada oito é reescrito de raiz. Publicar só a mediana seria escolher o número a dedo.

Os 16 de baixo não são um número a esconder. *São a lista de trabalho: cada um vira regra nova ou caso de ensaio.*

Um sistema destes não se mede pelo modelo que usa. *Mede-se pelo que está escrito à volta dele.*

A base é a única fonte que ele pode citar. O código decide o que é seguro revelar. E cada correção do lojista volta a entrar como regra. O modelo escreve o texto; nada disto é ele.

Quanto do teu sistema com LLM é prompt, e quanto é regra de negócio escrita à mão?