

A melhor otimização foi a que decidi *não fazer*.

Construí um agente que lê a caixa de apoio ao cliente de uma loja online e escreve rascunhos. Achei que a parte difícil ia ser a escrita.

Foi o custo.

Isto correu numa caixa a sério, não num playground.

453

emails processados
em produção

0

enviados sem
revisão humana

66%

escalados para
uma pessoa

Corre de dois em dois minutos. Para cada email escolhe entre rascunhar, escalar ou descartar. Tudo o que pode ser decidido em código é decidido antes de o modelo ver o caso: provar identidade, somar prazos, filtrar ruído.

O modelo escreve. Uma pessoa envia. Sempre.

89% de acerto de cache parecia resolvido.

O registo não guardava tokens nenhuns. A única fonte era a fatura mensal, agregada e impossível de atribuir a um email. Antes de otimizar seja o que for, instrumentei.

\$0,0107

ler o prefixo
que está em cache

\$0,2147

reescrevê-lo num
arranque a frio

Escrever custa vinte vezes o que custa ler. Por isso *os 11% de falhas custavam 2,4× mais do que todos os acertos somados.*

O problema nunca foi o prompt ser grande. Era o número de vezes que era reescrito.

Havia duas entradas de cache, não uma.

O esquema de saída faz parte do prefixo em cache. Como as duas chamadas usavam esquemas diferentes, nunca partilhavam nada. Num arranque a frio, uma escalação reescrevia o prompt inteiro duas vezes.

A hipótese era evidente: um esquema só, uma entrada só, e metade da escrita desaparecia.


Podia ter feito o deploy nessa tarde. Toda a gente teria concordado que era uma melhoria.

ANTES DE O FAZER, TESTEI

MEDIDO · O TESTE CUSTOU \$0,008

Teria falhado em todas as chamadas.

Tempo de resposta, por número de propriedades no esquema de saída



Não é uma degradação, é uma paragem. Acima do timeout falha sempre, não falha às vezes. E o custo não é linear, por isso aparar um campo ou dois também não salvava.

Uma otimização rejeitada depois de um teste *é um bom resultado de engenharia.*

66% escalavam. Quis baixar o número.

A leitura fácil é “há aqui muito por automatizar”. Passei um dia a ler os motivos, um a um.

Ação sobre encomenda	103	exige escrita na plataforma
Compromisso anterior	95	estado que ninguém regista
Julgamento humano	52	garantia, litígio, exceção
Outras seis categorias	47	contexto, identidade, lacuna

Testei a hipótese mais promissora, a dos reembolsos: **2 de 9** já estavam registados. Nos outros 7 estava mesmo por processar.

Baixar aquela percentagem exigia dar ao agente escrita na loja, *que é exatamente o guardrail que torna isto tolerável.*

Um guardrail de prompt contorna-se. Um de infraestrutura não.

Sem Mail.Send

A aplicação nunca pediu a permissão de envio ao Microsoft Graph. Não é uma regra no código que alguém possa contornar. É uma permissão que não existe.

Só leitura na loja

O agente lê encomendas e não escreve nenhuma. Nada do que ele decida pode mover dinheiro ou alterar um envio.

Mesmo que todos os outros falhem em simultâneo, o pior resultado possível é *um rascunho errado que uma pessoa lê e apaga.*

Nenhum email sai. Nenhuma encomenda muda.

Cada edição do lojista é um requisito por escrever.

Quando ele muda um rascunho antes de o enviar, está a corrigir uma regra que eu não escrevi.

01 Compara o gerado com o que foi mesmo enviado

02 Agrupa pelo padrão, não pelo email

03 Às 19h o sistema manda-lhe três, no Discord

04 Ele responde. Uma pessoa escreve a regra

Pergunta o *porquê*, nunca propõe a resposta. Uma concordância educada dá uma regra pior do que nenhuma regra.

Na ronda de 3 de setembro: uma pergunta não gerou regra, outra alargou um gatilho, e a terceira revelou um defeito meu.

O custo caiu 63%. Não foi de graça.

	30–31 AGO	2–3 SET	
Tokens pagos por email	19 998	7 443	-63%
Chamadas ao modelo por email	1,73	1,00	-42%
Emails resolvidos com rascunho	23%	40%	+17 p.p.
Rascunhos enviados sem mudar uma palavra	79%	74%	-5 p.p.

A última linha é o preço. O sistema passou a escrever rascunhos em casos que antes escalava, e atacar casos mais difíceis faz descer a percentagem que sai intacta.

Cinco pontos por dezassete parece-me boa troca. Mas é uma troca, e prefiro escrevê-la do que arredondá-la.

Não prova causalidade: entraram três alterações na mesma janela.

A métrica certa não era quantos casos automatizei. *Era quantos consegui automatizar com segurança.*

Uma média pode esconder uma assimetria de preço, e só se vê depois de instrumentar. Uma hipótese rejeitada por medição é um resultado. E nem toda a automação por fazer é dívida.

Qual foi a otimização que mediste e decidiste não fazer?